



ROBOCAP 1.0

Andrés Jaramillo Barón - A01029079
Pedro Mauri Martínez - A01029143

¿QUÉ ES ROBOCAP?

Sistema que recibe
una imagen...



... y devuelve una
descripción de lo que se ve
en la imagen

APLICACIÓN OBJETIVO

(Robotica)

- Robots asistentes.
- Navegación autónoma.
- Sistemas que necesitan interpretar su ambiente, en formas que los humanos entiendan.



DATASET USADO

(COCO)



Common Objects in Context


Proyecto dedicado a diseñar un dataset de imágenes para usar en proyectos de detección de objetos.



Images

Listas de archivos de imagen .jpg

- 118k de training.
- 5k de validation.
- 41k de testing.



Instances

Archivo .json con información de cada objeto de cada imagen.

(object id, image id, category_id, segmentación, area y iscrowd)



Captions

Archivo .json con 5 o 6 descripciones de cada imagen en el dataset.



<https://cocodataset.org/#download>

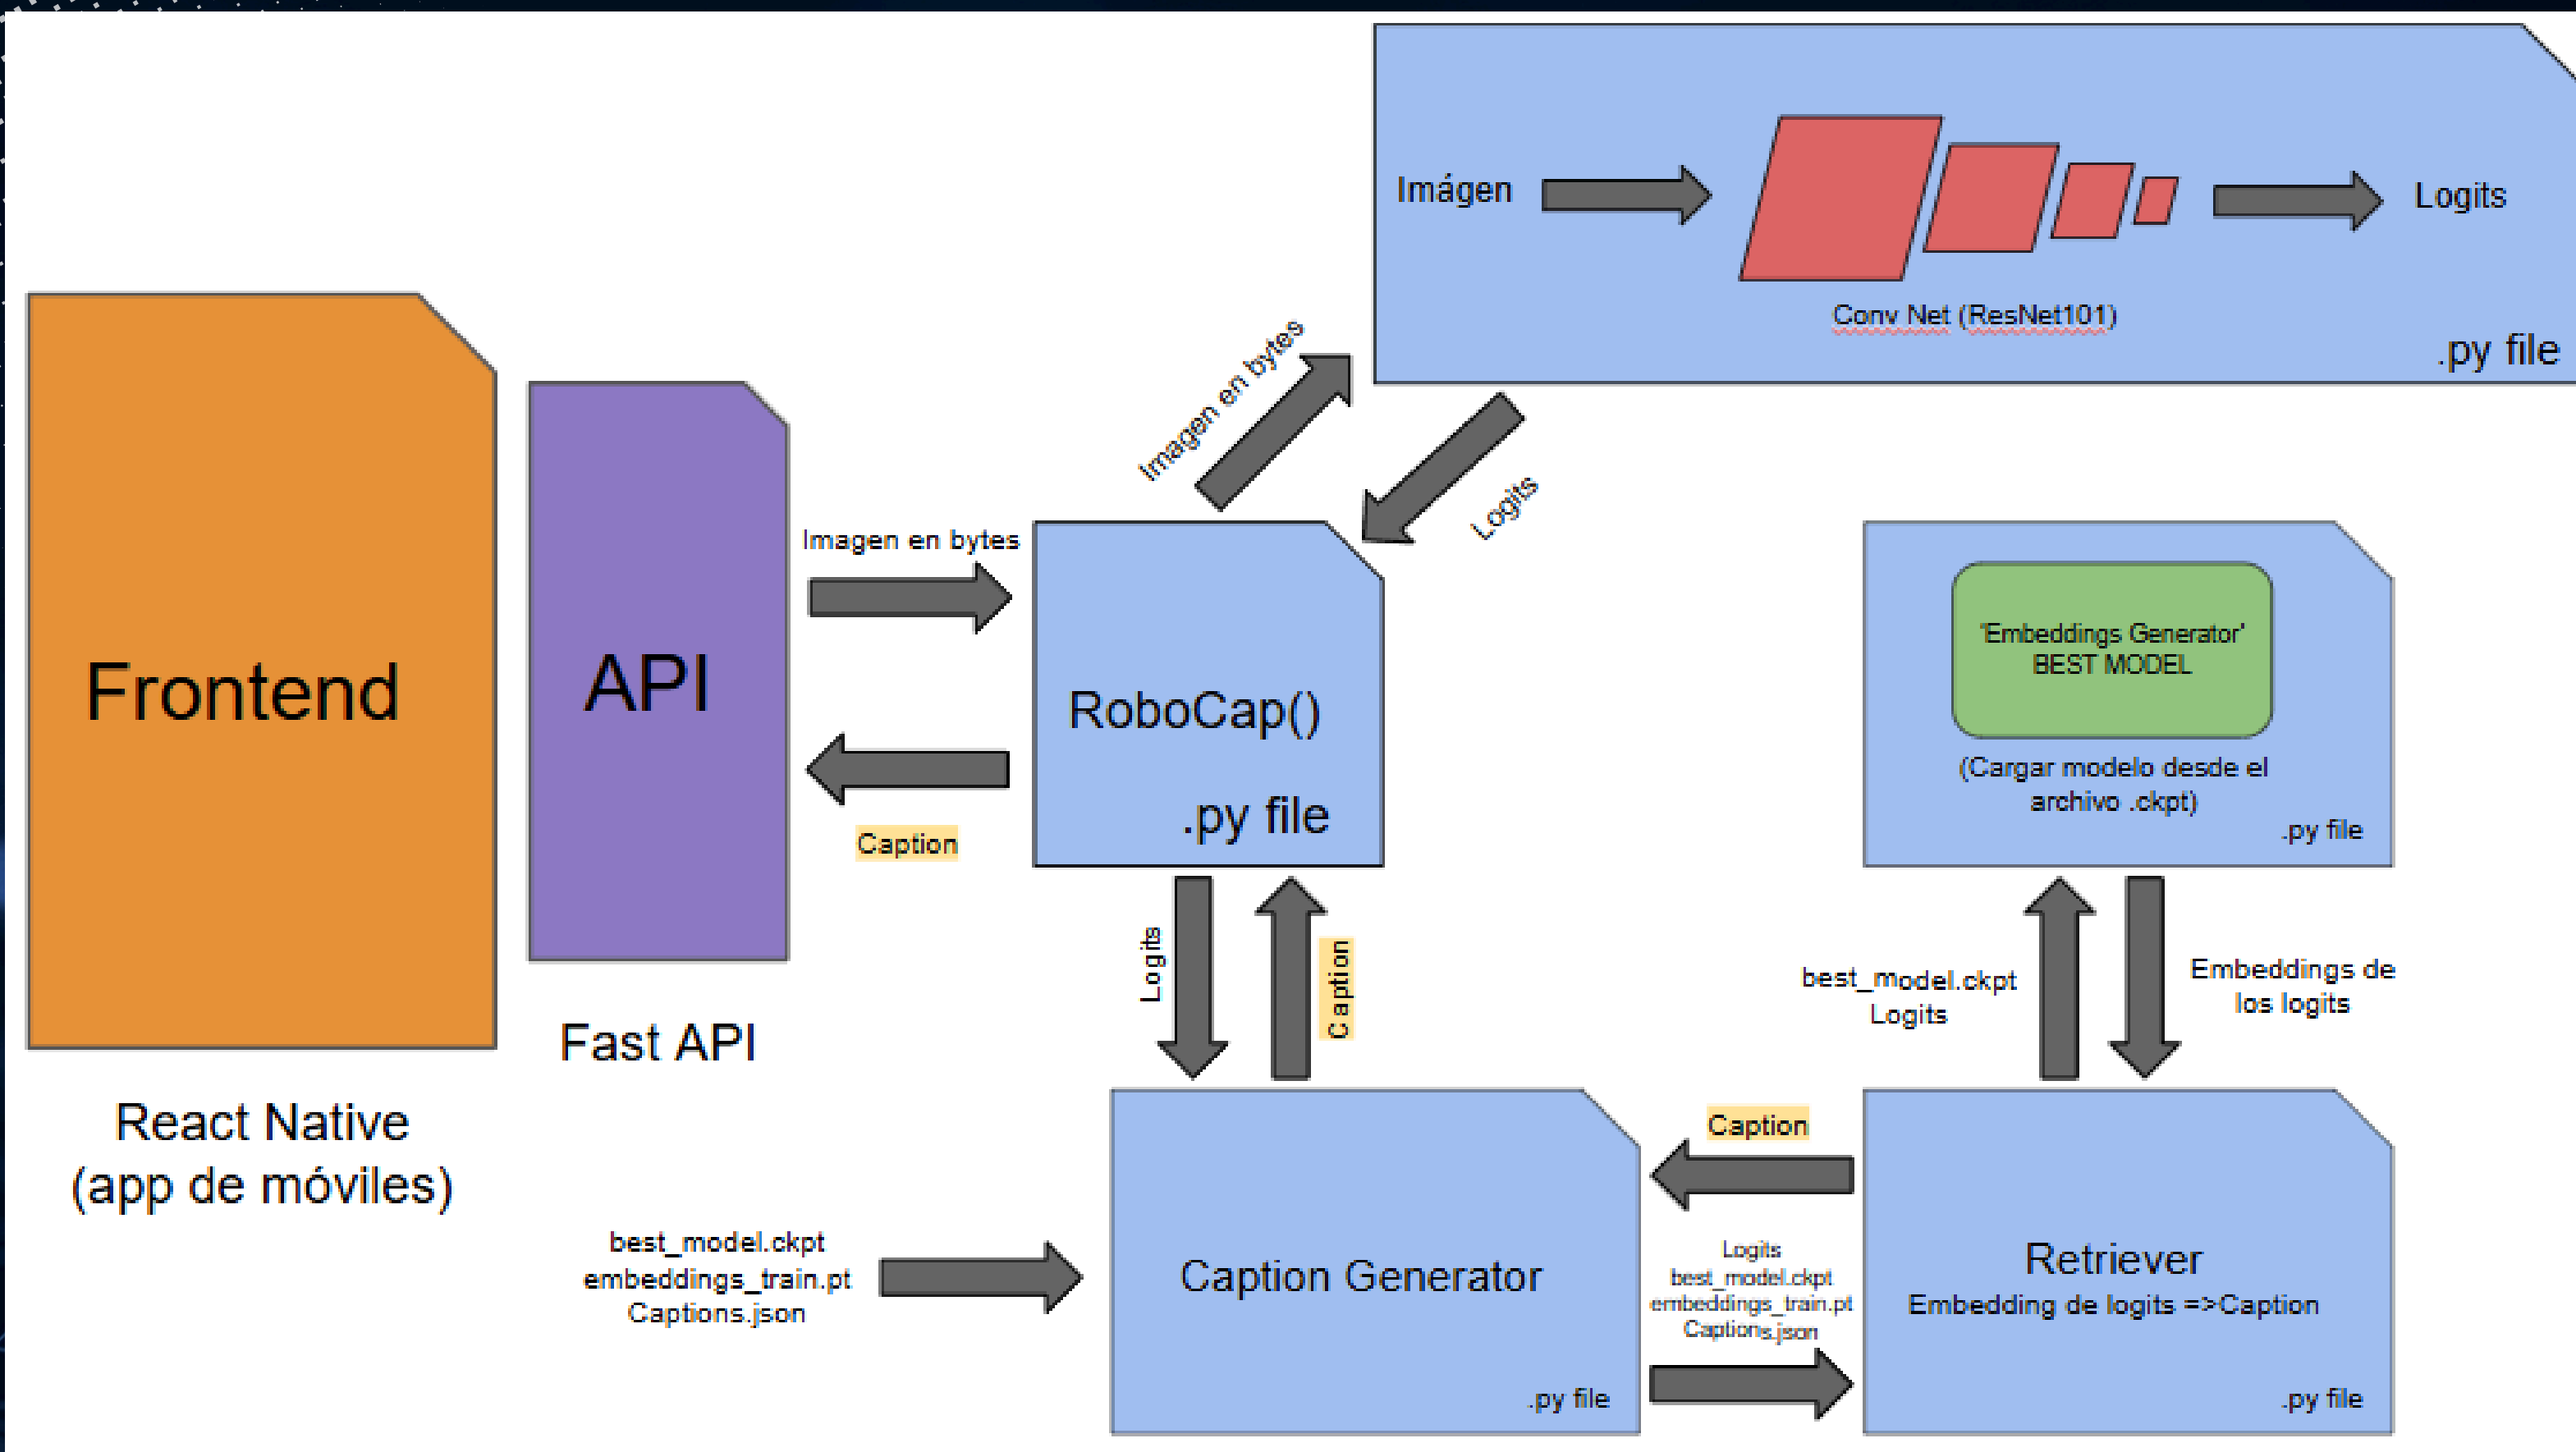
PIPELINE




ARQUITECTURA DE PROYECTO

- Feature extraction
 - Procesamiento de datasets
 - Logits y Embeddings (train & val)
- Training model
 - BERT model
- Deployed project
 - Frontend.
 - API
 - Modelo en modo eval()






DETALLES DE LOS MODELOS



Red Conv

Se utilizó la red ResNet101 con sus pesos preentrenados de PyTorch sin capa de clasificador, para que regresara los logits.



BERT


Se utilizó el transformer BERT llamado "bert-base-uncased" con pesos preentrenados de Hugging Face



BERT (train)

Este modelo se entrena en un archivo .ipynb usando cross entropy y se guarda su mejor checkpoint en un archivo .ckpt.

(train_acc = 65 | val_acc = 69)
(train_loss = 1.63 | val_loss = 1.51)



BERT (eval)

Este modelo carga los pesos del modelo entrenado guardado en el archivo .ckpt y únicamente regresa el embedding de los logits

BERT ARQUITECTURE

01

Recibe logits

Se calcula el tamaño del tensor de los logits, para darle ese valor al `in_features` de BERT

02

Normalización de logits

Como los logits pueden variar mucho entre sí, y BERT es muy sensible a ese tipo de datos, estos se normalizan.

Y para evitar overfitting, se hace dropout

03

Logits a Embeddings

Convertir logits normalizados a embeddings.
Ya que BERT esta hecho para recibir tokens y no logits.

04

Pasar por BERT

Los embeddings (logits) se los mandamos a BERT. para que genere el CLS.

BERT ARQUITECTURE



IDEAS DE MEJORAS



Implementación de LLM

En lugar de encontrar el embedding más cercano guardado; generar un texto nuevo con el embeddings creado.



Ampliar el dataset

Con más imágenes y más captions de entrenamiento, RoboCap podría identificar una mayor cantidad de contextos para describir.

DEMO ROBOCAP 1.0

RoboCap

Take a photo or pick one from your library. RoboCap will generate a caption.

📷 Take photo

🖼️ Gallery



✓ Caption generated

Caption

Several people in matching black outfits holding umbrellas.

RoboCap

Take a photo or pick one from your library. RoboCap will generate a caption.

📷 Take photo

🖼️ Gallery



✓ Caption generated

Caption

An assortment of fruit with oranges and bananas

RoboCap

Take a photo or pick one from your library. RoboCap will generate a caption.

📷 Take photo

🖼️ Gallery



✓ Caption generated

Caption

A parked silver Nissan Titan four door pickup truck.

DEMO ROBOCAP 1.0